

概述

统计方法步骤

1. 得到一个有限的训练数据结合
2. 确定学习模型的集合（模型）
3. 确定模型选择的准则（策略）
4. 实现求解最优模型的算法（算法）
5. 通过学习方法选择最优模型
6. 利用学习的最优模型对新数据进行预测或分析

统计学习方法的分类

按算法分类

- 在线学习：每次获得一个样本，进行学习
- 批量学习：一次接受所有数据，进行学习

按技巧分类

- 贝叶斯学习
- 核方法

基本分类

- 监督学习
- 无监督学习
- 强化学习

按模型分类

- 概率模型 非概率模型
- 线性模型 非线性模型
- 参数化模型（参数量固定） 非参数化模型

基本分类

监督学习

基本概念

- 输入空间：输入的所有可能取值的集合
- 实例：每一个具体的输入，通常由特征向量表示
- 特征空间：所有特征向量存在的空间
- 输出空间：输出的所有可能取值的集合

问题分类

- 回归问题：**输入输出变量**均连续
- 分类问题：**输出变量**为有限个离散变量
- 标注问题：**输入输出变量**均为变量序列的预测问题

基本假设

- 假设： X 和 Y 具有联合概率分布 $P(X, Y)$
- 目的：学习一个输入到输出的映射，这一映射以模型表示
- 模型的形式：条件概率分布 $P(Y|X)$ 或决策函数 $Y = f(X)$


无监督学习

从无标注数据中学习预测模型的机器学习问题，学习数据中的统计规律或潜在结构。

基本假设

- 输入空间： X
- 隐式结构空间： Z
- 模型：函数 $z = g(x)$,条件概率分布 $P(z|x)$ 或条件概率分布 $P(x|z)$

强化学习



正则化和交叉验证

正则化

正则化：实现结构风险最小化策略

- 一般形式：

$$\min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)) + \lambda J(f)$$

- 经验风险：

$$\frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i))$$

- 正则化项：

$$\lambda J(f)$$

其中， λ 权衡经验风险和模型复杂度

- L_1 范数：

$$L(w) = \frac{1}{N} \sum_{i=1}^N (f(x_i; w) - y_i)^2 + \lambda \|w\|_1$$

其中， $\|w\|_1 = \sum_j |w_j|$

- L_2 范数：

$$L(w) = \frac{1}{N} \sum_{i=1}^N (f(x_i; w) - y_i)^2 + \frac{\lambda}{2} \|w\|_2^2$$

其中， $\|w\|_2 = \sqrt{\sum_j w_j^2}$, $\|w\|_2^2 = \sum_j w_j^2$

- L_1 参数适合做特征筛选，使某些参数直接为0，得到一个**稀疏模型**（非零参数很少）
- L_2 参数可以使得模型越来越简单


奥卡姆剃刀原理

在模型选择时，选择所有可能模型中，能**很好解释已知数据并且十分简单**的模型。

交叉验证

数据不足情况下：

- S 折交叉验证：随机将数据分为 S 个**互不相交、大小相同**的子集，其中以 $S - 1$ 个子集作为训练集，余下的子集作为测试集。



- 留一交叉验证： S 折交叉验证的特殊情形， $S = N$ 。

泛化能力

泛化误差

模型对未知数据预测的误差即为泛化误差。

泛化误差上界

泛化误差的概率上界。

性质

- 当样本容量增加时，泛化上界趋于0
- 假设空间容量越大（可以选择的模型数量越多），模型就越难学，泛化误差上界就越大

生成模型与判别模型

生成模型

生成模型

由数据学习联合分布概率 $P(X, Y)$ ，然后求出 $P(Y|X)$ 作为预测模型，即生成模型（Generative Model）：

$$P(Y|X) = \frac{P(X, Y)}{P(X)}$$

典型的生成模型：朴素贝叶斯法、隐马尔可夫模型

注：输入和输出变量要求为随机变量

判别模型

判别模型

由数据直接学习决策函数 $f(X)$ 或者 条件概率分布 $P(Y|X)$ 作为预测模型，即判别模型（Discriminative Model）

典型的判别模型： k 近邻法、感知机、决策树等

注：不需要输入和输出变量均为随机变量

对比

- 生成模型
 - i. 所需数据量大
 - ii. 可还原概率分布 $P(X, Y)$
 - iii. 收敛速度更快
 - iv. 能反映同类数据本身的相似度
 - v. 隐变量存在时，仍可用生成模型
- 判别模型
 - i. 所需样本的数量少于生成模型
 - ii. 可直接面对预测，准确率更高
 - iii. 可简化学习问题
 - iv. 不可以反映数据本身的特性