

感知机

感知机介绍

- 输入空间: $\mathcal{X} \subseteq \mathbf{R}^n$; 输入: $x = (x^{(1)}, x^{(2)}, \dots, x^{(n)})^T \in \mathcal{X}$
- 输出空间: $\mathcal{Y} = \{+1, -1\}$; 输出: $y \in \mathcal{Y}$
- 感知机:

$$f(x) = \text{sign}(w \cdot x + b) = \begin{cases} +1, & w \cdot x + b \geq 0 \\ -1, & w \cdot x + b < 0 \end{cases}$$

其中, $w = (w^{(1)}, w^{(2)}, \dots, w^{(n)})^T \in \mathbf{R}^n$ 称为权值 (Weight), $b \in \mathbf{R}$ 称为偏置 (Bias), $w \cdot x$ 表示内积

$$w \cdot x = w^{(1)}x^{(1)} + w^{(2)}x^{(2)} + \dots + w^{(n)}x^{(n)}$$

- 假设空间: $\mathcal{F} = \{f \mid f(x) = w \cdot x + b\}$

学习策略

如何判定一个点是否正确分类

- $\forall x_0 \in \mathbf{R}^n$ 到 $\mathbf{S}$ 的距离:

$$\frac{1}{\|w\|} |w \cdot x_0 + b|$$

- 若 x_0 是正确分类点, 则

$$\frac{1}{\|w\|} |w \cdot x_0 + b| = \begin{cases} \frac{w \cdot x_0 + b}{\|w\|}, & y_0 = +1 \\ -\frac{w \cdot x_0 + b}{\|w\|}, & y_0 = -1 \end{cases}$$

- 若 x_0 是错误分类点, 则

$$\frac{1}{\|w\|} |w \cdot x_0 + b| = \begin{cases} -\frac{w \cdot x_0 + b}{\|w\|}, & y_0 = +1 \\ \frac{w \cdot x_0 + b}{\|w\|}, & y_0 = -1 \end{cases} = \frac{-y_0(w \cdot x_0 + b)}{\|w\|}$$

如何表征损失函数

- 误分类点 x_i 到 $\mathbf{S}$ 的距离:

$$-\frac{1}{\|w\|} y_i (w \cdot x_i + b)$$

- 所有误分类点到 $\mathbf{S}$ 的距离:

$$-\frac{1}{\|w\|} \sum_{x_i \in M} y_i (w \cdot x_i + b)$$


其中, M 代表所有误分类点的集合。

- 损失函数:

$$L(w, b) = - \sum_{x_i \in M} y_i (w \cdot x_i + b)$$

梯度下降法

基本概念



- 梯度，指
某一函数在该点处最大的方向导数，
沿着该方向可取得最大的变化率。

$$\nabla = \frac{\partial f(\theta)}{\partial \theta}$$

- 若 $f(\theta)$ 是凸
函数，可通过梯度下降法进行优化：

$$\theta^{(k+1)} = \theta^{(k)} - \eta \nabla f(\theta^{(k)})$$

具体算法

输入：目标函数 $f(\theta)$ ，步长 η ，计算精度 ϵ ；
输出： $f(\theta)$ 的极小点 θ^* 。

- (1) 选取初始值 $\theta^{(0)} \in \mathbf{R}^n$ ，置 $k = 0$ 。
- (2) 计算 $f(\theta^{(k)})$ 。
- (3) 计算梯度 $\nabla f(\theta^{(k)})$ 。
- (4) 置 $\theta^{(k+1)} = \theta^{(k)} - \eta \nabla f(\theta^{(k)})$ ，计算 $f(\theta^{(k+1)})$
当 $||f(\theta^{(k+1)}) - f(\theta^{(k)})|| < \epsilon$ 或者 $||\theta^{(k+1)} - \theta^{(k)}|| < \epsilon$ 时，停止迭代，令 $\theta^* = \theta^{(k+1)}$ 。
- (5) 否则，置 $k = k + 1$ ，转(3)

感知机原始形式算法

原始形式为随机梯度下降法：

基本信息

损失函数：

$$L(w, b) = - \sum_{x_i \in M} y_i (w \cdot x_i + b)$$

梯度：

$$\nabla_w L(w, b) = - \sum_{x_i \in M} y_i x_i; \quad \nabla_b L(w, b) = - \sum_{x_i \in M} y_i$$

参数更新：

- 批量梯度下降法（Batch Gradient Descent）：每次迭代时使用所有误分类点来进行参数更新。

$$\begin{aligned} w &\leftarrow w + \eta \sum_{x_i \in M} y_i x_i; & b &\leftarrow b + \eta \sum_{x_i \in M} y_i \end{aligned}$$

其中， $\eta(0 < \eta \leq 1)$ 代表步长。

- 随机梯度下降法（Stochastic Gradient Descent）：每次随机选取一个误分类点。

$$\begin{aligned} w &\leftarrow w + \eta y_i x_i; & b &\leftarrow b + \eta y_i \end{aligned}$$

训练流程


输入：训练集：

$$T = \{(x_1, y_1), (x_2, y_2) \cdots, (x_N, y_N)\}$$

其中， $x_i \in \mathcal{X} \subseteq \mathbf{R}^n$ ， $y \in \mathcal{Y} = \{+1, -1\}$ ；步长 $\eta(0 < \eta \leq 1)$

输出： w, b ；感知机模型 $f(x) = \text{sign}(w \cdot x + b)$

- (1) 选取初始值 w_0, b_0 ；
- (2) 于训练集中随机选取数据 (x_i, y_i) ；
- (3) 若 $y_i(w \cdot x_i + b) \leq 0$,
 $w \leftarrow w + \eta y_i x_i; \quad b \leftarrow b + \eta y_i$
- (4) 转(2)，直到训练集中没有误分类点。



感知机对偶形式算法

基本信息

- 在原始形式中，若 (x_i, y_i) 为误分类点，可如下更新参数：
$$w \leftarrow w + \eta y_i x_i; \quad b \leftarrow b + \eta y_i$$
- 假设初始值 $w_0 = 0, b_0 = 0$ ，对误分类点 (x_i, y_i) 通过上述公式更新参数，修改 n_i 次之后， w, b 的增量分别为 $\alpha_i y_i x_i$ 和 $\alpha_i y_i$ ，其中 $\alpha_i = n_i \eta$ 。
- 最后学习到的参数为，
$$w = \sum_{i=1}^N \alpha_i y_i x_i; \quad b = \sum_{i=1}^N \alpha_i y_i$$

训练流程

输入：训练集：

$$T = \{(x_1, y_1), (x_2, y_2) \cdots, (x_N, y_N)\}$$

其中， $x_i \in \mathcal{X} \subseteq \mathbf{R}^n$ ， $y \in \mathcal{Y} = \{+1, -1\}$ ；步长 $\eta(0 < \eta \leq 1)$

输出： α, b ；感知机模型 $f(x) = \text{sign}(\sum_{j=1}^N \alpha_j y_j x_j \cdot x + b)$ ，其中 $\alpha = (\alpha_1, \alpha_2, \cdots, \alpha_N)^T$

- (1) 选取初始值 $\alpha^{<0>} = (0, 0, \cdots, 0)^T, b^{<0>} = 0$ ；
- (2) 于训练集中随机选取数据 (x_i, y_i) ；
- (3) 若 $y_i(\sum_{j=1}^N \alpha_j y_j x_j \cdot x_i + b) \leq 0$,
 $\alpha_i \leftarrow \alpha_i + \eta; \quad b \leftarrow b + \eta y_i$
- (4) 转(2)，直到训练集中没有误分类点。