

朴素贝叶斯

贝叶斯定理

基本思维

基本方法是：先验概率 -> 调整因子 -> 后验概率。形象说明就是：主观判断 -> 添加新信息 -> 最终结论。

贝叶斯分类

已知：

存在 K 类 $c_1, c_2, \dots, c_K$ ，给定一个新的实例 $x = (x^{(1)}, x^{(2)}, \dots, x^{(n)})$

问：该实例归属哪一类？

•

$$P(Y = c_i | X = x) = \frac{P(X = x | Y = c_i) \cdot P(Y = c_i)}{\sum_{i=1}^K P(X = x | Y = c_i) \cdot P(Y = c_i)}$$

•

$$\arg \max_{c_i} P(X = x | Y = c_i) \cdot P(Y = c_i)$$

上述为贝叶斯的公式，具体而言就是通过先验概率来计算出后验概率

朴素贝叶斯公式如下：

存在 K 类 $c_1, c_2, \dots, c_K$ ，给定一个新的实例 $x = (x^{(1)}, x^{(2)}, \dots, x^{(n)})$

问：该实例归属哪一类？

•

$$P(Y = c_i | X = x) = \frac{P(Y = c_i) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_i)}{\sum_{i=1}^K P(Y = c_i) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_i)}$$

•

$$\arg \max_{c_i} P(Y = c_i) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_i)$$

由于分母是一致的，所以只需要关注分子即可，因此最大化时，最大化的是分子大小，朴素贝叶斯推导过程如下：

假设：实例特征之间相互独立

$$\begin{aligned}P(X = x|Y = c_i) &= \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_i) \\ \Rightarrow P(X = x) &= \sum_{i=1}^K P(Y = c_i) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_i) \\ \Rightarrow P(Y = c_i|X = x) &= \frac{P(X = x|Y = c_i) \cdot P(Y = c_i)}{\sum_{i=1}^K P(Y = c_i) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_i)} \\ \Rightarrow P(Y = c_i|X = x) &= \frac{P(Y = c_i) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_i)}{\sum_{i=1}^K P(Y = c_i) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_i)}\end{aligned}$$

朴素贝叶斯：因何朴素

基本方法

生成方法：学习联合概率分布

$$\underline{P(X, Y)}$$

- 先验概率分布：

$$P(Y = c_i), \quad i = 1, 2, \dots, K$$

- 条件概率分布：

$$P(X = x|Y = c_i) = P(X^{(1)} = x^{(1)}, \dots, X^{(n)} = x^{(n)}|Y = c_i)$$

- 联合概率分布：

$$P(X, Y) = P(X = x|Y = c_i)P(Y = c_i), i = 1, 2, \dots, K$$

为什么要假设条件独立

随着特征数的增多，输入向量 x 的取值有了更多的可能，同样的输出向量 y 也有了更多的可能，随着特征数的增长，这些取值的可能数量是以指数级增长的。因此假设特征独立，能够使得取值不必全部罗列。

后验概率最大化

存在 K 类 $c_1, c_2, \dots, c_K$ ，给定一个新的实例 $x = (x^{(1)}, x^{(2)}, \dots, x^{(n)})$

问：该实例归属哪一类？

- 后验概率

$$P(Y = c_i|X = x) = \frac{P(Y = c_i) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_i)}{\sum_{i=1}^K P(Y = c_i) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_i)}$$

- 分类

$$y = \arg \max_{c_i} P(Y = c_i) \prod_{j=1}^n P(X^{(j)} = x^{(j)}|Y = c_i)$$

成功将期望风险最小化转化为后验概率最大化。（证明未在这里写出）

极大似然法

为了最大化后验概率而提出的算法。

计算的准备

以下先验概率和条件概率

x, y
分类

$c_k \in \{c_1, c_2, \dots, c_K\}$

$n \in \mathbb{R}^n$

$y = \arg \max_{c_k} P(Y = c_k) \prod_{j=1}^n P(X^{(j)} = x^{(j)} | Y = c_k)$ 总体

• 先验概率:

$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N}, k = 1, 2, \dots, K$

• 条件概率:

$P(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_{i=1}^N I(y_i = c_k)}, l = 1, 2, \dots, S_j$

$\{a_{1l}, \dots, a_{jS_j}\}$

训练集 样本

其中 y 是最后需要最大化的后验概率

最大化方法

具体可以的解法有三类

- 遍历解：将所有取值空间的值全部试一遍，找出最大的后验概率，进而求得对应的值。
- 解析解：利用高等数学知识进行求导

• 直接通过似然函数 $L(\beta)$ 求解

- 当 $L(\beta)$ 可微时，可通过方程组

$\beta = (\beta_1, \beta_2, \dots, \beta_m)^T$

$\left\{ \begin{aligned} \frac{\partial L(\beta)}{\partial \beta_1} &= 0, \frac{\partial L(\beta)}{\partial \beta_2} = 0, \dots, \frac{\partial L(\beta)}{\partial \beta_m} = 0 \end{aligned} \right.$

求得 $L(\beta)$ 的极大值点

- 当 $L(\beta)$ 不存在偏导数时，需要直接研究 $L(\beta)$ ，寻找最大值点。

• 通过对数似然函数 $\ln L(\beta)$ 求解 $\hat{\beta}$ 也是 $\ln L(\beta)$ 的最大值点，

- 当 $\ln L(\beta)$ 可微时，可通过下列方程组，

$\frac{\partial \ln L(\beta)}{\partial \beta_1} = 0, \frac{\partial \ln L(\beta)}{\partial \beta_2} = 0, \dots, \frac{\partial \ln L(\beta)}{\partial \beta_m} = 0$

求解，判断根是不是最大值点。

- 当 $\ln L(\beta)$ 不存在偏导数时，需要研究 $\ln L(\beta)$ ，寻找最大值点。

- 迭代法：EM步，得到一个近似解

实际算法


基本信息：

输入：训练集：

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$$

实例 $x = (x^{(1)}, x^{(2)}, \dots, x^{(n)})$;

输出：实例 x 所属类别 y



其中后验概率即为需要优化的 y 。通过此方法可以通过前验概率计算出后验概率。

贝叶斯估计

估计方法

- 先验概率的贝叶斯估计

$$P_{\lambda}(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K\lambda}$$

- 条件概率的贝叶斯估计

$$P_{\lambda}(X_{ij}^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k) + \lambda}{\sum_{i=1}^N I(y_i = c_k) + S_j \lambda}$$

注： $\lambda \geq 0$ $\lambda = 0$ 时为极大似然估计， $\lambda = 1$ 时为拉普拉斯平滑(Laplacian Smoothing)。

估计例子

$$P(\theta|Y) = \frac{P(Y|\theta)P(\theta)}{P(Y)}$$

例： Y 分为两类 c_1, c_2 ，相应参数为 θ_1 ，假设参数服从均匀分布 $U(0, 1)$ ，求参数 θ_1 的贝叶斯估计。

- 参数 θ_1 的先验概率

$$f(\theta_1) = 1$$

- 已知 θ_1 时 Y 的条件概率

$$g(Y|\theta_1) = \begin{cases} \theta_1, & Y = c_1 \\ 1 - \theta_1, & Y = c_2 \end{cases}$$

为什么需要平滑项（即估计方法中的 λ ）

- 贝叶斯估计：

$$P_{\lambda}(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K\lambda}$$

- 正则化：


$$\min_{f \in \mathcal{F}} \frac{1}{N} \sum_{i=1}^N L(y_i, f(x_i)) + \lambda J(f)$$

加入先验概率既为了避免过拟合，同时也可以避免除0的问题。

其中 K 是在这个属性(Y)上的空间数量。

最后的结果是极大似然概率 + $\lambda \times$ 先验概率

解法可以参照：



- Y 左侧的概率为先验概率
- Y 与 X 的交点上为条件概率