

最大熵模型

最大熵原理

离散部分

如下为最大熵定义，以及在常规约束条件下的结果

$$\begin{aligned} \max H &= - \sum_{i=1}^k p_i \log p_i & 0 \leq H \leq \log_2 k \\ \begin{array}{c|cccc} X & x_1 & x_2 & \dots & x_k \\ \hline P & p_1 & p_2 & \dots & p_k \end{array} & \boxed{\sum_{i=1}^k p_i = 1} \\ \max_{p_i} & - \sum_{i=1}^k p_i \log p_i + \lambda (\sum_{i=1}^k p_i - 1) \\ \frac{\partial}{\partial p_i} &= -(\log p_i + 1) + \lambda = 0 \Rightarrow p_i = 2^{\lambda-1} \\ \sum_{i=1}^k p_i &= k \cdot 2^{\lambda-1} = 1 \Rightarrow 2^{\lambda-1} = \frac{1}{k} \\ \Rightarrow p_i &= \frac{1}{k} \quad i=1, 2, \dots, k \end{aligned}$$

连续部分

在连续随机变量的均值为 μ ，方差为 σ^2 ，则最大熵对应的概率分布应该正态分布。
利用拉格朗日乘子法后求导，可以逐步得到该结论。

模型介绍

Definition (最大熵模型)

假设满足所有约束条件的模型集合为

$$\mathcal{C} = \{P \in \mathcal{P} | E_P(f_i) = E_{\tilde{P}}(f_i), \quad i = 1, 2, \dots, n\}$$

定义在条件概率分布 $P(Y|X)$ 上的条件熵为

$$H(P) = - \sum_{x,y} \tilde{P}(x) P(y|x) \log P(y|x)$$

则模型集合 $\mathcal{C}$ 中条件熵 $H(P)$ 最大的模型称为最大熵模型。

第一个式子代表着满足条件的模型集合，第二个在计算**条件熵**。使用条件分布而不是联合分布是因为该模型是生成模型，目标是条件分布。

针对于上图中的经验分布，可以通过如下方式加入约束。

C

$$p(y|x) = \frac{p(x,y)}{p(x)}$$

真实 经验

$$E_P(f_i) = E_{\tilde{P}}(f_i), \quad i = 1, 2, \dots, n \quad x_1, x_2, \dots, x_m$$

$$E_P(f_i) = \sum_{x,y} p(x,y) f_i(x,y)$$

$$= \sum_{x,y} \underbrace{p(x)}_{\tilde{p}(x)} \underbrace{p(y|x)}_{\tilde{p}(x=x_i, y=g_j)} f_i(x,y)$$

$$\approx \sum_{x,y} \tilde{p}(x) \tilde{p}(y|x) f_i(x,y)$$

$$E_{\tilde{P}}(f_i) = \sum_{x,y} \tilde{p}(x,y) f_i(x,y) = \frac{v(X=x_i, Y=g_j)}{N}$$

$\tilde{p}(X=x_i) = \frac{v(X=x_i)}{N}$
 $C_1, C_2, \dots, C_k$
 $\tilde{p}(X=x_i, Y=g_j)$

经过变换后成功得到了求和后等于某个经验值的约束。

转化为数学的原始问题后，可以得到优化的目标是：

若 $f(x)$, $c_i(x)$, $h_j(x)$ 是定义在 R^n 上的连续可微函数。考虑如下有约束的最优化问题：

$$\begin{aligned} \min_{x \in R^n} \quad & f(x) \\ \text{s.t.} \quad & c_i(x) \leq 0, \quad i = 1, 2, \dots, k \\ & h_j(x) = 0, \quad j = 1, 2, \dots, l \end{aligned} \quad k+l \uparrow$$

这就是该有约束最优化问题的原始形式。

广义拉格朗日函数：

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)$$

进而考虑如何最优化问题

Primal

广义拉格朗日函数：

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)$$

考虑x的函数

$$\theta_P(x) = \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta)$$

$\theta_P(x) = \begin{cases} f(x) & \text{有约束} \\ +\infty & \text{其他} \end{cases}$

原始问题的最优值：

$$p^* = \min_x \theta_P(x) = \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta)$$

更进一步在原始问题的基础上进行拓展，拓展为对偶问题：

广义拉格朗日函数：

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)$$

原始问题的最优值：

$$\min L \leq L \leq \max L$$

$$p^* = \min_x \theta_P(x) = \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta)$$

对偶问题的最优值：

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta) = \max_{\alpha, \beta: \alpha_i \geq 0} \min_x L(x, \alpha, \beta)$$

进一步得到：

Theorem (原始问题与对偶问题)

若原始问题与对偶问题都有最优值，则

$$d^* \leq p^*$$

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \min_x L(x, \alpha, \beta) \leq \min_x \max_{\alpha, \beta: \alpha_i \geq 0} L(x, \alpha, \beta) = p^*$$

$$\underbrace{\min_x L(x, \alpha, \beta)}_{\max \theta_D(\alpha, \beta)} \leq L(x, \alpha, \beta) \leq \underbrace{\max_{\alpha, \beta} L(x, \alpha, \beta)}_{\min \theta_P(x)}$$

KTT条件

广义拉格朗日函数：

$$L(x, \alpha, \beta) = f(x) + \sum_{i=1}^k \alpha_i c_i(x) + \sum_{j=1}^l \beta_j h_j(x)$$

Theorem (KKT 条件)

若函数 $f(x)$ 和 $c_i(x)$ 是凸函数， $h_j(x)$ 是仿射函数；并且假设不等式约束 $c_i(x)$ 是严格可行的，则 x^* 是原始问题的解， α^*, β^* 是对偶问题的解的充分必要条件是

$$\begin{aligned} \nabla_x L(x^*, \alpha^*, \beta^*) &= 0 \\ \alpha_i^* c_i(x^*) &= 0, & i = 1, 2, \dots, k \\ c_i(x^*) &\leq 0, & i = 1, 2, \dots, k \\ \alpha_i^* &\geq 0, & i = 1, 2, \dots, k \\ h_j(x^*) &= 0, & j = 1, 2, \dots, l \end{aligned}$$

最大熵模型的学习

- 最大熵模型的学习 $\iff$ 求解约束最小化问题：

$$\begin{aligned} \min_{P \in C} \\ \text{s.t.} \end{aligned}$$

$$\begin{aligned} -H(P) &= \sum_{x,y} \tilde{P}(x) P(y|x) \log P(y|x) \\ E_P(f_i) - E_{\tilde{P}}(f_i) &= 0 \quad i = 1, 2, \dots, n \\ \sum_y P(y|x) - 1 &= 0 \end{aligned}$$

- 采用拉格朗日乘子法

$$\begin{aligned} L(P, \omega) &= -H(P) + \omega_0 \left(1 - \sum_y P(y|x) \right) + \sum_{i=1}^n \omega_i \left(E_{\tilde{P}}(f_i) - E_P(f_i) \right) \\ &= \sum_{x,y} \tilde{P}(x) P(y|x) \log P(y|x) + \omega_0 \left(1 - \sum_y P(y|x) \right) \\ &\quad + \sum_{i=1}^n \omega_i \left(\sum_{x,y} \tilde{P}(x, y) f(x, y) - \sum_{x,y} \tilde{P}(x) P(y|x) f(x, y) \right) \end{aligned}$$

可以证明出来 $H(P)$ 是一个严格凸函数，证明略。

最后可以得到的条件概率是：

- 拉格朗日函数

$$L(P, \omega) = \sum_{x,y} \tilde{P}(x) P(y|x) \log P(y|x) E_P(f_i) + \omega_0 \left(1 - \sum_y P(y|x) \right) + \sum_{i=1}^n \omega_i \left(\sum_{x,y} \tilde{P}(x, y) f_i(x, y) - \sum_{x,y} \tilde{P}(x) P(y|x) f_i(x, y) \right)$$

- 分布

$$P(y|x) = \exp \left(\sum_{i=1}^n w_i f_i(x, y) + \omega_0 - 1 \right) = \frac{\exp \left(\sum_{i=1}^n w_i f_i(x, y) \right)}{\exp(1 - \omega_0)}$$

其中分母存在未知数，利用概率求和为1可以解析出 w_0 的结果.

- 分布

$$P(y|x) = \exp \left(\sum_{i=1}^n w_i f_i(x, y) + \omega_0 - 1 \right) = \frac{\exp \left(\sum_{i=1}^n w_i f_i(x, y) \right)}{\exp(1 - \omega_0)}$$

- 解

$$P_{\omega}(y|x) = \frac{1}{Z_{\omega}(x)} \exp \left(\sum_{i=1}^n w_i f_i(x, y) \right)$$

- 规范化因子

$$Z_{\omega}(x) = \sum_y \exp \left(\sum_{i=1}^n w_i f_i(x, y) \right)$$

最后**将条件概率带入到 $L(P, w)$ **即可.

至此内部极小化问题已经解决，下面需要解决外部极大化问题。

具体而言步骤应该如下：

- 对偶问题

$$\max_{\omega} \min_{P \in \mathcal{C}} L(P, \omega)$$

- 对偶问题的内部极小化问题

$$\min_{P \in \mathcal{C}} L(P, \omega) \quad \Psi(\omega)$$

- 对偶问题的外部极大化问题

$$\max_{\omega} \Psi(\omega)$$

- 拉格朗日乘子的解

$$\omega^* = \arg \max_{\omega} \Psi(\omega)$$

- 条件概率分布

$$P_{\omega^*} = \frac{1}{Z_{\omega^*}(x)} \exp \left(\sum_{i=1}^n w_i^* f_i(x, y) \right)$$

注意无论是内部极小化还是外部极大化针对的主要还是 $L(P, w)$ ，对 w 求导时也是对极小化产生的结果求导。

w 的求解方式有很多。

对得到的结果进行化简得到的结果于极大似然估计的结果一致，因此对偶函数等价于对数似然函数。

- 条件概率分布
- 规范化因子

$$P_{\omega}(y|x) = \frac{1}{Z_{\omega}(x)} \exp \left(\sum_{i=1}^n w_i f_i(x, y) \right)$$
$$Z_{\omega}(x) = \sum_y \exp \left(\sum_{i=1}^n w_i f_i(x, y) \right)$$

在已知经验分布的条件下，求条件概率分布 $P(Y|X)$ 的对数似然函数

$$L_{\tilde{P}}(P_{\omega}) = \log \prod_{x,y} P_{\omega}(y|x)^{\tilde{P}(x,y)} = \sum_{x,y} \tilde{P}(x,y) \log P_{\omega}(y|x)$$

① 离散 1
连续 2
② 对象：
日本

优化算法

梯度下降法

- 迭代公式
- 一阶泰勒展开
- 最优步长

$$\theta^{(k+1)} = \theta^{(k)} - \underbrace{\eta \nabla f(\theta^{(k)})}_{\substack{\text{方向} \\ \text{步长} \\ \text{位移}}}$$
$$f(\theta) \approx f(\theta^{(k)}) + (\theta - \theta^{(k)}) \nabla f(\theta^{(k)})$$
$$\eta^{(k)} = \arg \min_{\eta} f(\theta^{(k)} - \eta \nabla f(\theta^{(k)}))$$

具体的步骤：

输入：目标函数 $f(\theta)$ ，梯度 $\nabla f(\theta)$ ，计算精度 ϵ ；

输出： $f(\theta)$ 的极小值点 θ^* 。

- (1) 选取初始值 $\theta^{(0)} \in \mathbf{R}^n$ ，置 $k = 0$ ；
- (2) 计算 $f(\theta^{(k)})$ 和梯度 $\nabla f(\theta^{(k)})$ ；
- (3) 计算最优步长 $\eta^{(k)} = \arg \min_{\eta} f(\theta^{(k)} - \eta \nabla f(\theta^{(k)}))$ ；
- (4) 利用迭代公式 $\theta^{(k+1)} = \theta^{(k)} - \eta^{(k)} \nabla f(\theta^{(k)})$ 进行参数更新；
- (5) 如果 $\|f(\theta^{(k+1)}) - f(\theta^{(k)})\| < \epsilon$ ，停止迭代，令 $\theta^* = \theta^{(k+1)}$ ，输出结果。否则，令 $k = k + 1$ ，转(3)继续迭代，更新参数，直到满足终止条件。

在最大熵模型中的步骤为：

输入：特征函数 $f_1, f_2, \dots, f_n$ ；经验分布 $\tilde{P}(x)$ 和 $\tilde{P}(x, y)$ ，目标函数 $f(\omega)$ ，梯度 $g(\omega)$ ，计算精度 ϵ ；

输出： $f(\omega)$ 的极小值点 ω^* ；最优模型 $P_{\omega^*}(y|x)$ 。

- (1) 选取初始值 $\omega^{(0)} \in \mathbf{R}^n$ ，置 $k = 0$ ；
- (2) 计算 $f(\omega^{(k)})$ 和梯度 $g(\omega^{(k)})$ ；
- (3) 计算最优步长 $\eta^{(k)} = \arg \min_{\eta} f(\omega^{(k)} - \eta g(\omega^{(k)}))$ ；
- (4) 利用迭代公式 $\omega^{(k+1)} = \omega^{(k)} - \eta^{(k)} g(\omega^{(k)})$ 进行参数更新；
- (5) 如果 $\|f(\omega^{(k+1)}) - f(\omega^{(k)})\| < \epsilon$ ，停止迭代，令 $\omega^* = \omega^{(k+1)}$ ，输出结果。否则，令 $k = k + 1$ ，转(3)继续迭代，更新参数，直到满足终止条件。
- (6) 将所得 ω^* 代入 $P_{\omega}(y|x)$ 中，即得最优条件概率分布模型

$$P_{\omega^*}(y|x) = \frac{\exp(\sum_{i=1}^n \omega_i^* f_i(x, y))}{\sum_y \exp(\sum_{i=1}^n \omega_i^* f_i(x, y))}$$

牛顿法

本质是求解零点，大致思想为：

1. 找函数在该点位置的切线
2. 利用切线与x轴的交点作为新的x值

具体求零点步骤是：

输入：目标函数 $g(\theta)$ ，梯度 $\nabla g(\theta) = g'(\theta)$ ，计算精度 ϵ ；

输出： $g(\theta)$ 的零点 θ^* 。

- (1) 选取初始值 $\theta^{(0)} \in \mathbf{R}^n$ ，置 $k = 0$ ；
- (2) 计算 $g(\theta^{(k)})$ 和梯度 $\nabla g(\theta^{(k)})$ ；
- (3) 利用迭代公式 $\theta^{(k+1)} = \theta^{(k)} - g(\theta^{(k)}) \frac{1}{\nabla g(\theta^{(k)})}$ 进行参数更新；
- (4) 如果 $\|g(\theta^{(k+1)})\| < \epsilon$ ，停止迭代，令 $\theta^* = \theta^{(k+1)}$ ，输出结果。否则，令 $k = k + 1$ ，转(2)继续迭代，更新参数，直到满足终止条件。

在实际运用的时候， $g(x)$ 是目标函数 $f(x)$ 的导函数。

多元情况下的牛顿法：

输入：目标函数 $f(\theta)$ ，梯度 $\nabla f(\theta) = g(\theta)$ ，海森矩阵 $H_f = \nabla g(\theta)$ ，计算精度 ϵ ；

输出： $f(\theta)$ 的最小值点 θ^* 。

- (1) 选取初始值 $\theta^{(0)} \in \mathbf{R}^n$ ，置 $k = 0$ ；
- (2) 计算 $f(\theta^{(k)})$ ，梯度 $\nabla f(\theta^{(k)})$ ，海森矩阵 $H_f(\theta^{(k)})$ ；
- (3) 利用迭代公式 $\theta^{(k+1)} = \theta^{(k)} - \nabla f(\theta^{(k)}) H_f(\theta^{(k)})^{-1}$ 进行参数更新；
- (4) 如果 $\|g(\theta^{(k+1)})\| < \epsilon$ ，停止迭代，令 $\theta^* = \theta^{(k+1)}$ ，输出结果。否则，令 $k = k + 1$ ，转(2)继续迭代，更新参数，直到满足终止条件。

拟牛顿法

因为逆矩阵的求解复杂度较高，因此采用拟牛顿法较好。拟牛顿法类似于牛顿法与梯度下降法的结合。

- DFP算法

输入：目标函数 $f(x)$ ，梯度 $g(x) = \nabla f(x)$ ，计算精度 ϵ ；

输出： $f(x)$ 的极小值点 x^* 。

(1) 选取初始值 $x^{(0)} \in \mathbf{R}^n$ 以及初始正定对称矩阵 G_0 ，置 $k = 0$ ；

(2) 计算 $g(x^{(k)})$ ，如果 $\|g_k\| < \epsilon$ ，停止迭代，令 $x^* = x^{(k)}$ ，输出结果。否则，转(3)继续迭代；

(3) 置 $p_k = -G_k g_k$ ，利用一维搜索公式得到最优步长 λ_k

$$\lambda_k = \arg \min_{\lambda \geq 0} f(x^{(k)} + \lambda p_k)$$

(4) 通过迭代公式更新

$$x^{(k+1)} = x^{(k)} + \lambda_k p_k$$

(5) 计算 $g(x^{(k+1)})$ ，如果 $\|g(x^{(k+1)})\| < \epsilon$ ，停止迭代，令 $x^* = x^{(k+1)}$ ，输出结果。否则，令 $k = k + 1$ ，计算

$$G_{k+1} = G_k + \frac{\delta_k \delta_k^T}{\delta_k^T y_k} - \frac{G_k y_k y_k^T G_k}{y_k^T G_k y_k}$$

转(3)继续迭代，更新参数，直到满足终止条件。

• BFGS算法

输入：目标函数 $f(x)$ ，梯度 $g(x) = \nabla f(x)$ ，计算精度 ϵ ；

输出： $f(x)$ 的极小值点 x^* 。

(1) 选取初始值 $x^{(0)} \in \mathbf{R}^n$ 以及初始正定对称矩阵 B_0 ，置 $k = 0$ ；

(2) 计算 $g(x^{(k)})$ ，如果 $\|g_k\| < \epsilon$ ，停止迭代，令 $x^* = x^{(k)}$ ，输出结果。否则，转(3)继续迭代；

(3) 置 $B_k p_k = -g_k$ ，求出 p_k ，利用一维搜索公式得到最优步长 λ_k

$$\lambda_k = \arg \min_{\lambda \geq 0} f(x^{(k)} + \lambda p_k)$$

(4) 通过迭代公式更新

$$x^{(k+1)} = x^{(k)} + \lambda_k p_k$$

(5) 计算 $g(x^{(k+1)})$ ，如果 $\|g(x^{(k+1)})\| < \epsilon$ ，停止迭代，令 $x^* = x^{(k+1)}$ ，输出结果。否则，令 $k = k + 1$ ，计算

$$B_{k+1} = B_k + \frac{y_k y_k^T}{y_k^T \delta_k} - \frac{B_k \delta_k \delta_k^T B_k}{\delta_k^T B_k \delta_k}$$

转(3)继续迭代，更新参数，直到满足终止条件。

迭代尺度法

这种方法能用于最大熵模型中

此处仅作简要说明：

输入：特征函数 $f_1, f_2, \dots, f_n$ ；经验分布 $\tilde{P}(x)$ 和 $\tilde{P}(x, y)$ ，模型 $P_\omega(y|x)$

输出：最优参数 ω^* ，最优模型 $P_{\omega^*}(y|x)$ 。

- (1) 对所有 $i \in \{1, 2, \dots, n\}$ ，选取初始值 $\omega_i = 0$

条件概率分布

$$P_\omega(y|x) = \frac{1}{Z_\omega(x)} \exp \left(\sum_{i=1}^n \omega_i f_i(x, y) \right)$$

$\frac{1}{\sum y}$

- (2) 分别计算每一次迭代的 δ_i ，然后进行参数更新：

- 根据方程求解 δ_i

$$\sum_{x,y} \tilde{P}(x) P_\omega(y|x) f_i(x, y) \exp(\delta_i f_i^\#(x, y)) = E_{\tilde{P}}(f_i)$$

- 更新参数 ω

$$\omega_i \leftarrow \omega_i + \delta_i$$

- (3) 重复以上步骤，通过迭代公式更新参数，直到收敛。

- (4) 将所得 ω^* 代入 $P_\omega(y|x)$ 中，即得最优条件概率分布模型

$$P_{\omega^*}(y|x) = \frac{\exp \left(\sum_{i=1}^n \omega_i^* f_i(x, y) \right)}{\sum_y \exp \left(\sum_{i=1}^n \omega_i^* f_i(x, y) \right)}$$