

EM算法

具体过程

算法 9.1 (EM 算法)

输入：观测变量数据 Y ，隐变量数据 Z ，联合分布 $P(Y, Z|\theta)$ ，条件分布 $P(Z|Y, \theta)$ ；

输出：模型参数 θ 。

(1) 选择参数的初值 $\theta^{(0)}$ ，开始迭代；

(2) E 步：记 $\theta^{(i)}$ 为第 i 次迭代参数 θ 的估计值，在第 $i+1$ 次迭代的 E 步，计算

$$\begin{aligned} Q(\theta, \theta^{(i)}) &= E_Z[\log P(Y, Z|\theta)|Y, \theta^{(i)}] \\ &= \sum_Z \log P(Y, Z|\theta) P(Z|Y, \theta^{(i)}) \end{aligned} \quad (9.9)$$

这里， $P(Z|Y, \theta^{(i)})$ 是在给定观测数据 Y 和当前的参数估计 $\theta^{(i)}$ 下隐变量数据 Z 的条件概率分布；

(3) M 步：求使 $Q(\theta, \theta^{(i)})$ 极大化的 θ ，确定第 $i+1$ 次迭代的参数的估计值 $\theta^{(i+1)}$

$$\theta^{(i+1)} = \arg \max_{\theta} Q(\theta, \theta^{(i)}) \quad (9.10)$$

(4) 重复第 (2) 步和第 (3) 步，直到收敛。 ■

通过先验知识 Y, θ 可以得到 Z 的条件概率分布，即 $P(Z|Y, \theta^{(i)})$ 。相当于先固定 θ ，得到隐变量 Z 的值，然后再求大化 Q 得到新的 θ 然后重复上述步骤。

E 步的主要目的是求解条件概率分布和得到损失函数，M 步主要目的是求得最小化损失函数对应的参数/

EM 算法结果与设置的初始值高度相关，所以要谨慎设置初始值。

高斯混合模型

混合高斯:

$\phi_1: N(\mu_1, \sigma_1^2), \phi_2: N(\mu_2, \sigma_2^2), \dots, \phi_K: N(\mu_K, \sigma_K^2) \quad \sum_{k=1}^K \phi_k = 1$

观测: $y_1, y_2, \dots, y_j, \dots, y_N$

$y_j = \begin{cases} 1 & \text{来自 } N(\mu_1, \sigma_1^2) \\ 0 & \text{否则} \end{cases}, y_j = \begin{cases} 1 & \text{来自 } N(\mu_2, \sigma_2^2) \\ 0 & \text{否则} \end{cases}, \dots, y_{jk}$

完整:

y_1	$y_{11}, y_{12}, \dots, y_{1K}$
y_2	$y_{21}, y_{22}, \dots, y_{2K}$
$\vdots$	$\vdots$
y_N	$y_{N1}, y_{N2}, \dots, y_{NK}$

参数: $\theta = (\phi_1, \mu_1, \sigma_1^2, \phi_2, \mu_2, \sigma_2^2, \dots, \phi_K, \mu_K, \sigma_K^2)$

隐变量

以上是基本的一些参数，其中 y 是观测值， γ 是隐变量。其中 $N()$ 代表着高斯分布，所以有 K 个高斯分布。

联合概率分布

$$P(y_1, \dots, y_N, \gamma | \theta) = \prod_{j=1}^N P(y_j, \gamma_{j1}, \dots, \gamma_{jK} | \theta)$$

$$= \prod_{j=1}^N \prod_{k=1}^K [\phi_k N(\mu_k, \sigma_k^2)]^{\gamma_{jk}}$$

$$= \prod_{k=1}^K \phi_k^{\sum_{j=1}^N \gamma_{jk}} \prod_{j=1}^N [N(\mu_k, \sigma_k^2)]^{\gamma_{jk}}$$

$$= \prod_{k=1}^K \phi_k^{\sum_{j=1}^N \gamma_{jk}} \prod_{j=1}^N \left[\frac{1}{\sqrt{2\pi}\sigma_k} e^{-\frac{(y_j - \mu_k)^2}{2\sigma_k^2}} \right]^{\gamma_{jk}}$$

其次是求解联合概率分布，将最开始的参数进行带入得到。

联合概率密度:

$$P(y_1, \dots, y_N, \gamma | \theta) = \prod_{k=1}^K \alpha_k^{n_k} \prod_{j=1}^N [\phi(y_j | \theta_k)]^{\gamma_{jk}}$$

$$\ln L(\theta) = \sum_{k=1}^K \left\{ n_k \ln \alpha_k + \sum_{j=1}^N \ln [\phi(y_j | \theta_k)]^{\gamma_{jk}} \right\}$$

$$\phi(y | \theta_k) = \frac{1}{\sqrt{2\pi}\sigma_k} e^{-\frac{(y - \mu_k)^2}{2\sigma_k^2}}$$

$$\hat{\gamma}_{jk} = \frac{\phi(y_j | \mu_k^{(i)}, \sigma_k^{(i)}) \alpha_k^{(i)}}{\sum_{k=1}^K \phi(y_j | \cdot, \cdot) \alpha_k^{(i)}}$$

$$\hat{n}_k = \sum_{j=1}^N \hat{\gamma}_{jk}$$

$$\hat{\gamma}_{jk} = E(\gamma_{jk} | y, \theta^{(i)})$$

$$= 1 \cdot P(\gamma_{jk}=1 | y, \theta^{(i)}) + 0 \cdot P(\gamma_{jk}=0 | y, \theta^{(i)})$$

$$= P(\gamma_{jk}=1 | y_j, \theta^{(i)}) = \frac{P(y_j | \gamma_{jk}=1, \theta^{(i)}) P(\gamma_{jk}=1 | \theta^{(i)})}{\sum_{k=1}^K P(y_j | \gamma_{jk}=1, \theta^{(i)}) P(\gamma_{jk}=1 | \theta^{(i)})}$$

贝叶斯公式

$$P(y_j | \theta^{(i)})$$

求解隐变量和损失函数。下面对E步进行总结，并且得到M步需要解决的问题。

E步: ① 在已知 $\theta^{(i)}$ 的情况下, 补全信息

$$\hat{\gamma}_{jk} \quad \hat{n}_k = \sum_{j=1}^N \hat{\gamma}_{jk}$$

$$\frac{\alpha_k^{(i)} \phi(y_j | \theta^{(i)})}{\sum_{k=1}^K \alpha_k^{(i)} \phi(y_j | \theta^{(i)})} \rightarrow \mu_k^{(i)}, \sigma_k^{(i)}$$

② 找到M步的目标函数

$$Q(\theta, \theta^{(i)}) = \sum_{k=1}^K \left\{ \hat{n}_k \ln \alpha_k + \sum_{j=1}^N \hat{\gamma}_{jk} \ln \phi(y_j | \mu_k, \sigma_k^2) \right\}$$

$$\text{s.t.} \quad \sum_{k=1}^K \alpha_k = 1 \quad \text{约束条件} \quad -\frac{1}{2} \ln(2\pi) - \frac{1}{2} \ln \sigma_k^2 - \frac{1}{2\sigma_k^2} (y_j - \mu_k)^2$$

$$M\text{步:} \quad \theta^{(i+1)} = \arg \max_{\theta} Q, \quad \text{s.t.} \quad \sum_{k=1}^K \alpha_k = 1$$

之后用拉格朗日乘子法即可得出结果为:

M步: $\theta^{(t+1)} = \arg \max_{\theta} Q, \text{ s.t. } \sum_{k=1}^K \alpha_k = 1$

$\hat{\alpha}_k = \frac{\hat{n}_k}{N}$ ✓. $\hat{\mu}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} y_j}{\hat{n}_k}$ ✓. $\hat{\sigma}_k^2 = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} (y_j - \hat{\mu}_k)^2}{\hat{n}_k}$ ✓

$N(\mu_k, \sigma_k^2)$

E步, M步: 迭代EM, 直到收敛, 输出结果 θ^* 3K个参数

求解M步: 有约束 $\Rightarrow$ 无约束 $\arg \max_{\theta, \lambda} \{ Q + \lambda (\sum_{k=1}^K \alpha_k - 1) \}$
 $\underbrace{\quad}_{3K+1} \quad \underbrace{\quad}_{Q_0}$

步骤大概可以认为是:

算法 9.2 (高斯混合模型参数估计的EM算法)

输入: 观测数据 $y_1, y_2, \dots, y_N$, 高斯混合模型;

输出: 高斯混合模型参数。

3K $\mu_k, \sigma_k^2, \alpha_k, k$

(1) 取参数的初始值开始迭代;

θ

(2) E 步: 依据当前模型参数, 计算分模型 k 对观测数据 y_j 的响应度

$$\hat{\gamma}_{jk} = \frac{\alpha_k \phi(y_j | \theta_k)}{\sum_{k=1}^K \alpha_k \phi(y_j | \theta_k)}, \quad j = 1, 2, \dots, N; \quad k = 1, 2, \dots, K$$

(3) M 步: 计算新一轮迭代的模型参数

$$\hat{\mu}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} y_j}{\sum_{j=1}^N \hat{\gamma}_{jk}}, \quad k = 1, 2, \dots, K$$

$$\hat{\sigma}_k^2 = \frac{\sum_{j=1}^N \hat{\gamma}_{jk} (y_j - \mu_k)^2}{\sum_{j=1}^N \hat{\gamma}_{jk}}, \quad k = 1, 2, \dots, K$$

$$\hat{\alpha}_k = \frac{\sum_{j=1}^N \hat{\gamma}_{jk}}{N}, \quad k = 1, 2, \dots, K$$

(4) 重复第 (2) 步和第 (3) 步, 直到收敛。

GEM算法

Generalized GLM 极大-极大 EM算法 Q函数

定义 9.3 (F 函数) 假设隐变量数据 Z 的概率分布为 $\tilde{P}(Z)$, 定义分布 $\tilde{P}$ 与参数 θ 的函数 $F(\tilde{P}, \theta)$ 如下:

$$F(\tilde{P}, \theta) = E_{\tilde{P}}[\log P(Y, Z|\theta)] + H(\tilde{P}) \quad (9.33)$$

称为 F 函数。式中 $H(\tilde{P}) = -E_{\tilde{P}} \log \tilde{P}(Z)$ 是分布 $\tilde{P}(Z)$ 的熵。

对数似然与 Q 函数

$$\log P(Y|\theta) = Q(\theta, \theta^{(i)}) - H(\theta, \theta^{(i)})$$

信息熵

$$= \sum_Z \underbrace{[\log P(Y, Z|\theta)]}_{\text{对象}} P(Z|Y, \theta^{(i)}) - \sum_Z [\log P(Z|Y, \theta)] P(Z|Y, \theta^{(i)})$$

具体步骤

定理 9.4 EM 算法的一次迭代可由 F 函数的极大-极大算法实现。

设 $\theta^{(i)}$ 为第 i 次迭代参数 θ 的估计, $\tilde{P}^{(i)}$ 为第 i 次迭代函数 $\tilde{P}$ 的估计。在第 $i+1$ 次迭代的两步为:

- (1) 对固定的 $\theta^{(i)}$, 求 $\tilde{P}^{(i+1)}$ 使 $F(\tilde{P}, \theta^{(i)})$ 极大化; 定理 9.1.9.2
- (2) 对固定的 $\tilde{P}^{(i+1)}$, 求 $\theta^{(i+1)}$ 使 $F(\tilde{P}^{(i+1)}, \theta)$ 极大化。定理 9.3

EM E 步期望最大化

$$\tilde{P}^{(i+1)} = P(Z|Y, \theta^{(i)})$$

$$\arg \max_{\theta} F(\tilde{P}^{(i+1)}, \theta)$$

$$\arg \max_{\theta} Q(\theta, \theta^{(i)}) + H(\tilde{P}^{(i+1)})$$

EM E 步中的目标函数最大化

更新

算法 9.3 (GEM 算法 1)

输入: 观测数据, F 函数;

输出: 模型参数。

- (1) 初始化参数 $\theta^{(0)}$, 开始迭代;
- (2) 第 $i+1$ 次迭代, 第 1 步: 记 $\theta^{(i)}$ 为参数 θ 的估计值, $\tilde{P}^{(i)}$ 为函数 $\tilde{P}$ 的估计, 求 $\tilde{P}^{(i+1)}$ 使 $\tilde{P}$ 极大化 $F(\tilde{P}, \theta^{(i)})$; 第一次
- (3) 第 2 步: 求 $\theta^{(i+1)}$ 使 $F(\tilde{P}^{(i+1)}, \theta)$ 极大化; 第二次
- (4) 重复 (2) 和 (3), 直到收敛。

由于很难直接取得最大值, 因此在此基础上进行改良:

算法 9.4 (GEM 算法 2)

输入: 观测数据, Q 函数;

输出: 模型参数。

(1) 初始化参数 $\theta^{(0)}$, 开始迭代;

(2) 第 $i+1$ 次迭代, 第 1 步: 记 $\theta^{(i)}$ 为参数 θ 的估计值, 计算

$$\begin{aligned} Q(\theta, \theta^{(i)}) &= E_Z[\log P(Y, Z|\theta)|Y, \theta^{(i)}] \\ &= \sum_Z P(Z|Y, \theta^{(i)}) \log P(Y, Z|\theta) \end{aligned}$$

(3) 第 2 步: 求 $\theta^{(i+1)}$ 使

$$\theta^{(i+1)} = \arg \max_{\theta} Q(\theta, \theta^{(i)})$$
$$Q(\theta^{(i+1)}, \theta^{(i)}) > Q(\theta^{(i)}, \theta^{(i)})$$

(4) 重复 (2) 和 (3), 直到收敛。 ■

结合坐标下降法, 再进行改良:

算法 9.5 (GEM 算法 3)

输入: 观测数据, Q 函数;

输出: 模型参数。

(1) 初始化参数 $\theta^{(0)} = (\theta_1^{(0)}, \theta_2^{(0)}, \dots, \theta_d^{(0)})$, 开始迭代;

(2) 第 $i+1$ 次迭代, 第 1 步: 记 $\theta^{(i)} = (\theta_1^{(i)}, \theta_2^{(i)}, \dots, \theta_d^{(i)})$ 为参数 $\theta = (\theta_1, \theta_2, \dots, \theta_d)$ 的估计值, 计算

$$\begin{aligned} Q(\theta, \theta^{(i)}) &= E_Z[\log P(Y, Z|\theta)|Y, \theta^{(i)}] \\ &= \sum_Z P(Z|y, \theta^{(i)}) \log P(Y, Z|\theta) \end{aligned}$$

(3) 第 2 步: 进行 d 次条件极大化:

首先, 在 $\theta_2^{(i)}, \dots, \theta_d^{(i)}$ 保持不变的条件下求使 $Q(\theta, \theta^{(i)})$ 达到极大的 $\theta_1^{(i+1)}$;

然后, 在 $\theta_1 = \theta_1^{(i+1)}, \theta_j = \theta_j^{(i)}, j = 3, 4, \dots, d$ 的条件下求使 $Q(\theta, \theta^{(i)})$ 达到极大的 $\theta_2^{(i+1)}$;

如此继续, 经过 d 次条件极大化, 得到 $\theta^{(i+1)} = (\theta_1^{(i+1)}, \theta_2^{(i+1)}, \dots, \theta_d^{(i+1)})$ 使得

$$Q(\theta^{(i+1)}, \theta^{(i)}) > Q(\theta^{(i)}, \theta^{(i)})$$

(4) 重复 (2) 和 (3), 直到收敛。 ■