

# 隐马尔可夫模型

## 马尔可夫链简介

随机变量  $X, Y, Z$  等 静态

随机过程  $X(t)$  动态

离散连续  $[0, 1]$

马尔可夫 ← 切比雪夫

序列  $\{S_1, S_2, \dots, S_T, \dots\}$

$P(S_{t+1} | S_1, S_2, \dots, S_t) = P(S_{t+1} | S_t)$

如果  $S_{t+1}$  只依赖于前一时刻  $S_t$ , 不依赖于  $S_1, \dots, S_{t-1}$ , 则称  $\{S_1, \dots, S_T, \dots\}$  为 马尔可夫链 (Markov Chain, MC)

马尔可夫性

该时刻状态仅依赖于前一时刻的状态。

初始状态分布  $\pi = (\pi_1, \pi_2, \dots, \pi_N)^T$

$\sum_{i=1}^N \pi_i = 1, 0 \leq \pi_i \leq 1$

马尔可夫链  $\pi$  初始状态分布  $\pi$

状态转移概率矩阵  $P$


晴天、多云、下雨

$P = \begin{bmatrix} 0.65 & 0.10 & 0.25 \\ 0.25 & 0.25 & 0.50 \\ 0.25 & 0.15 & 0.60 \end{bmatrix}$

$\pi = (0.90, 0.05, 0.05)^T$

三天之后



$P^3 \pi = \begin{bmatrix} 0.43 \\ 0.38 \\ 0.38 \end{bmatrix}$



马尔可夫链最重要的两个初始值为：初始状态分布，状态转移概率矩阵。

## 隐马尔可夫模型

由原来的两要素变为三要素。



有初始状态分布概率  $\pi$ ，状态转移概率矩阵  $A$ ，观测概率矩阵  $B$ 。

## 观测序列的生成

根据隐马尔可夫模型定义，可以将一个长度为  $T$  的观测序列  $O = (o_1, o_2, \dots, o_T)$  的生成过程描述如下。

### 算法 10.1 (观测序列的生成)

输入：隐马尔可夫模型  $\lambda = (A, B, \pi)$ ，观测序列长度  $T$ ；

输出：观测序列  $O = (o_1, o_2, \dots, o_T)$ 。

- (1) 按照初始状态分布  $\pi$  产生状态  $i_1$ ；
- (2) 令  $t = 1$ ；
- (3) 按照状态  $i_t$  的观测概率分布  $b_{i_t}(k)$  生成  $o_t$ ；
- (4) 按照状态  $i_t$  的状态转移概率分布  $\{a_{i_t i_{t+1}}\}$  产生状态  $i_{t+1}$ ， $i_{t+1} = 1, 2, \dots, N$ ；
- (5) 令  $t = t + 1$ ；如果  $t < T$ ，转步 (3)；否则，终止。 ■

# 概率计算算法

## 直接计算法

概率计算算法 模型  $\lambda = (\pi, A, B)$  Janneil博士 Bilibili

① 直接计算法 ✓ 观测  $O = (o_1, o_2, \dots, o_T)$

② 前向算法  $I = (i_1, i_2, \dots, i_T)$   $3 \times 3$

③ 后向算法  $P(O|\lambda)$   $3 \times 3 \times 3$


$= \sum_I P(O, I|\lambda)$   $3 \times 3 \times 3 \dots \times 3 = 3^T$

乘法公式  $T \times N^T$

$P(O, I|\lambda) = P(I|\lambda) P(O|I, \lambda)$

$P(I|\lambda) = \pi_{i_1} a_{i_1 i_2} a_{i_2 i_3} \dots a_{i_{T-1} i_T}$

$P(O|I, \lambda) = b_{i_1}(o_1) b_{i_2}(o_2) \dots b_{i_T}(o_T)$



## 前向算法

不同于直接计算法统计可能的方案数，前向算法计算的是到每个状态的概率。

**算法 10.2 (观测序列概率的前向算法)**

输入: 隐马尔可夫模型  $\lambda$ , 观测序列  $O$ ;

输出: 观测序列概率  $P(O|\lambda)$ 。

(1) 初值

$$\alpha_1(i) = \pi_i b_i(o_1), \quad i = 1, 2, \dots, N \quad (10.15)$$

(2) 递推 对  $t = 1, 2, \dots, T-1$ ,

$$\alpha_{t+1}(i) = \left[ \sum_{j=1}^N \alpha_t(j) a_{ji} \right] b_i(o_{t+1}), \quad i = 1, 2, \dots, N \quad (10.16)$$

(3) 终止

$$P(O|\lambda) = \sum_{i=1}^N \alpha_T(i) \quad (10.17)$$

# 后向算法

算法 10.3 (观测序列概率的后向算法)

输入: 隐马尔可夫模型  $\lambda$ , 观测序列  $O$ ;

输出: 观测序列概率  $P(O|\lambda)$ 。

(1)

$$\beta_T(i) = 1, \quad i = 1, 2, \dots, N \tag{10.19}$$

(2) 对  $t = T - 1, T - 2, \dots, 1$

$$\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(o_{t+1}) \beta_{t+1}(j), \quad i = 1, 2, \dots, N \tag{10.20}$$

(3)

$$P(O|\lambda) = \sum_{i=1}^N \pi_i b_i(o_1) \beta_1(i) \tag{10.21}$$

■

# Baum-Welch算法

算法 10.4 (Baum-Welch 算法)

输入: 观测数据  $O = (o_1, o_2, \dots, o_T)$ ;

输出: 隐马尔可夫模型参数。

(1) 初始化。对  $n = 0$ , 选取  $a_{ij}^{(0)}, b_j(k)^{(0)}, \pi_i^{(0)}$ , 得到模型  $\lambda^{(0)} = (A^{(0)}, B^{(0)}, \pi^{(0)})$ 。

(2) 递推。对  $n = 1, 2, \dots$ ,

$$a_{ij}^{(n+1)} = \frac{\sum_{t=1}^{T-1} \xi_t(i, j)}{\sum_{t=1}^{T-1} \gamma_t(i)}$$
$$b_j(k)^{(n+1)} = \frac{\sum_{t=1, o_t=v_k}^T \gamma_t(j)}{\sum_{t=1}^T \gamma_t(j)}$$
$$\pi_i^{(n+1)} = \gamma_1(i)$$

右端各值按观测  $O = (o_1, o_2, \dots, o_T)$  和模型  $\lambda^{(n)} = (A^{(n)}, B^{(n)}, \pi^{(n)})$  计算。式中  $\gamma_t(i), \xi_t(i, j)$  由式 (10.24) 和式 (10.26) 给出。

(3) 终止。得到模型参数  $\lambda^{(n+1)} = (A^{(n+1)}, B^{(n+1)}, \pi^{(n+1)})$ 。

■


内容不全，懒得补了。

可以简单认为，这些估计是根据  $\frac{\text{从原状态转移到目标状态的样本数量}}{\text{原状态的样本数量}}$  得到的。

# 预测算法

## 近似算法

利用前向算法得出的结果和后向算法得出的结果一起进行计算。对于每个状态，将对应位置的前向结果和后向结果相乘即可得到概率，选择每个对应时刻下的最大值，即为预测结果。



逐点地预测，没有关注全局信息。

## 维特比算法

通过动态规划的思想进行预测。

### 算法 10.5 (维特比算法)

输入: 模型  $\lambda = (A, B, \pi)$  和观测  $O = (o_1, o_2, \dots, o_T)$ ;

输出: 最优路径  $I^* = (i_1^*, i_2^*, \dots, i_T^*)$ 。

(1) 初始化

$$\delta_1(i) = \pi_i b_i(o_1), \quad i = 1, 2, \dots, N$$

$$\Psi_1(i) = 0, \quad i = 1, 2, \dots, N$$

(2) 递推。对  $t = 2, 3, \dots, T$

$$\left\{ \begin{array}{l} \delta_t(i) = \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}] b_i(o_t), \quad i = 1, 2, \dots, N \\ \Psi_t(i) = \arg \max_{1 \leq j \leq N} [\delta_{t-1}(j) a_{ji}], \quad i = 1, 2, \dots, N \end{array} \right.$$

(3) 终止

$$P^* = \max_{1 \leq i \leq N} \delta_T(i)$$

$$i_T^* = \arg \max_{1 \leq i \leq N} [\delta_T(i)]$$

(4) 最优路径回溯。对  $t = T-1, T-2, \dots, 1$

$$i_t^* = \Psi_{t+1}(i_{t+1}^*)$$

求得最优路径  $I^* = (i_1^*, i_2^*, \dots, i_T^*)$ 。

相当于在不断地向前计算概率的同时，保留到该节点的最佳路径，最终选择概率最大的作为终点节点。