


条件随机场


概率无向图

无向图




马尔可夫性

- 成对马尔可夫性



两个节点没有直接相连，被其他节点隔开，那么就是条件独立的。

- 局部马尔可夫性




$$\begin{aligned}
 P(Y_v, Y_o | Y_w) &= \frac{P(Y_v | Y_w)}{P(Y_v, Y_o | Y_w)} P(Y_o | Y_w) \\
 &= P(Y_v | Y_w) P(Y_o | Y_w) \\
 &= P(Y_v | Y_o, Y_w)
 \end{aligned}$$

图 11.1 局部马尔可夫性

一个节点与一组节点没有直接相连，则也具有条件独立性。

• 全局马尔可夫性



$$\begin{aligned}
 P(Y_v, Y_o | Y_w) &= \frac{P(Y_v | Y_w)}{P(Y_v, Y_o | Y_w)} P(Y_o | Y_w) \\
 &= P(Y_v | Y_w) P(Y_o | Y_w) \\
 &= P(Y_v | Y_o, Y_w)
 \end{aligned}$$

图 11.1 全局马尔可夫性

一组节点与一组节点没有直接相连。则有条件独立性。

具体定义

定义 11.1 (概率无向图模型) 设有联合概率分布 $P(Y)$ ，由无向图 $G = (V, E)$ 表示，在图 G 中，结点表示随机变量，边表示随机变量之间的依赖关系。如果联合概率分布 $P(Y)$ 满足成对、局部或全局马尔可夫性，就称此联合概率分布为概率无向图模型 (probabilistic undirected graphical model)，或马尔可夫随机场 (Markov random field)。

① 无向图 $G = (V, E)$

② 联合概率分布 $P(Y)$ Y - 组随机变量 $\in Y$
边决定关系


③ 条件独立性 $\hookrightarrow$ 成对马尔可夫性
(简化) 局部
 全局

$P(Y)$ 概率无向图

因子分解

团的定义

定义 11.2 (团与最大团) 无向图 G 中任何两个结点均有边连接的结点子集称为团 (clique)。若 C 是无向图 G 的一个团, 并且不能再加进任何一个 G 的结点使其成为一个更大的团, 则称此 C 为最大团 (maximal clique)。



两个结点 1
三个结点 $C_3^2 = 3$
四个结点 $C_4^2 = \frac{4 \times 3}{2} = 6$

两个结点组成的团: $\{Y_1, Y_2\}, \{Y_2, Y_4\}, \{Y_3, Y_4\}, \{Y_1, Y_3\}$
三个结点组成的团: $\{Y_1, Y_2, Y_3\}, \{Y_2, Y_4, Y_3\}$

所有的最大团 $C \quad \mathbb{I}_C(Y_C) \quad \bar{Z} P(Y) = 1 \Rightarrow \bar{Z} \frac{1}{Z} \prod_C \mathbb{I}_C(Y_C) = 1$

$\mathbb{I}_C(Y_C) = e^{-E(Y_C)}$
 $P(Y) = \frac{1}{Z} \prod_C \mathbb{I}_C(Y_C)$, $Z = \sum_Y \prod_C \mathbb{I}_C(Y_C)$
Energy 能量

最大熵模型

结合条件随机场理解最大熵模型

最大熵模型

Definition (最大熵模型)
假设满足所有约束条件的模型集合为
 $C = \{P \in \mathcal{P} | E_P(f_i) = E_P(f_i), i = 1, 2, \dots, n\}$
定义在条件概率分布 $P(Y|X)$ 上的条件熵为
 $H(P) = - \sum_{x,y} \bar{P}(x) P(y|x) \log P(y|x)$
则模型集合 C 中条件熵 $H(P)$ 最大的模型称为最大熵模型。



最大熵模型的学习

- 分布
 $P(y|x) = \exp \left(\sum_{i=1}^n w_i f_i(x, y) + \omega_0 - 1 \right) = \frac{\exp \left(\sum_{i=1}^n w_i f_i(x, y) \right)}{\exp(1 - \omega_0)}$
- 解
 $P_\omega(y|x) = \frac{1}{Z_\omega(x)} \exp \left(\sum_{i=1}^n w_i f_i(x, y) \right)$
- 规范化因子
 $Z_\omega(x) = \sum_y \exp \left(\sum_{i=1}^n w_i f_i(x, y) \right)$

$P(Y|x)$
 $= \frac{1}{Z} \prod_{i=1}^n \exp(w_i f_i(x, y))$
 $E_i = -w_i f_i(x, y)$

条件随机场的定义

定义 11.3 (条件随机场) 设 X 与 Y 是随机变量, $P(Y|X)$ 是在给定 X 的条件下 Y 的条件概率分布。若随机变量 Y 构成一个由无向图 $G = (V, E)$ 表示的马尔可夫随机场, 即

$$P(Y_v|X, Y_w, w \neq v) = P(Y_v|X, Y_w, w \sim v) \quad (11.8)$$

对任意结点 v 成立, 则称条件概率分布 $P(Y|X)$ 为条件随机场。式中 $w \sim v$ 表示在图 $G = (V, E)$ 中与结点 v 有边连接的所有结点 w , $w \neq v$ 表示结点 v 以外的所有结点, Y_v , Y_u 与 Y_w 为结点 v , u 与 w 对应的随机变量。

只需要理会与边相连的结点, 有向边则考虑方向性

$P(Y|X)$ 极大似然法 —— 概率最大化 ✓
最大熵 —— 信息最大化

只需要找到所有与目标节点直接相连的节点即可, 与所有除了目标节点作为条件算出来的概率一致。

线性链条件随机场

定义 11.4 (线性链条件随机场) 设 $X = (X_1, X_2, \dots, X_n)$, $Y = (Y_1, Y_2, \dots, Y_n)$ 均为线性链表示的随机变量序列, 若在给定随机变量序列 X 的条件下, 随机变量序列 Y 的条件概率分布 $P(Y|X)$ 构成条件随机场, 即满足马尔可夫性

$$P(Y_i|X, Y_1, \dots, Y_{i-1}, Y_{i+1}, \dots, Y_n) = P(Y_i|X, Y_{i-1}, Y_{i+1}) \quad i=2, \dots, n$$

$i = 1, 2, \dots, n$ (在 $i = 1$ 和 n 时只考虑单边) (11.9)

则称 $P(Y|X)$ 为线性链条件随机场。在标注问题中, X 表示输入观测序列, Y 表示对应的输出标记序列或状态序列。

条件随机场的参数化形式

线性链 条件概率分布

定理 11.1 (Hammersley-Clifford 定理) 概率无向图模型的联合概率分布 $P(Y)$ 可以表示为如下形式:

$$P(Y) = \frac{1}{Z} \prod_C \psi_C(Y_C)$$

$$Z = \sum_Y \prod_C \psi_C(Y_C)$$

其中, C 是无向图的最大团, Y_C 是 C 的结点对应的随机变量, $\psi_C(Y_C)$ 是 C 上定义的严格正函数, 乘积是在无向图所有的最大团上进行的。

最大团 相邻两个结点的集合

权值 λ_k

边 $t_k(y_{i-1}, y_i, x, i)$ 是/否 (1/0)

结点 $s_i(y_i, x, i)$

图中更侧重于针对于线性链的特化。

接下来是正式的定义:

定理 11.2 (线性链条件随机场的参数化形式) 设 $P(Y|X)$ 为线性链条件随机场, 则在随机变量 X 取值为 x 的条件下, 随机变量 Y 取值为 y 的条件概率具有如下形式:

$$P(y|x) = \frac{1}{Z(x)} \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right) \quad (11.10)$$

其中,

$$Z(x) = \sum_y \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} \mu_l s_l(y_i, x, i) \right) \quad (11.11)$$

式中, t_k 和 s_l 是特征函数, λ_k 和 μ_l 是对应的权值. $Z(x)$ 是规范化因子, 求和是在所有可能的输出序列上进行的.

条件随机场的简化形式

$f_k(y_{i-1}, y_i, x, i) = \begin{cases} t_k(y_{i-1}, y_i, x, i), & k=1, 2, \dots, K_1 \text{ 转移} \\ s_l(y_i, x, i), & k=K_1+l, l=1, 2, \dots, K_2 \text{ 状态} \end{cases}$

$f_k(y, x) = \sum_{i=1}^n f_k(y_{i-1}, y_i, x, i), \quad k=1, \dots, K$

$w_k = \begin{cases} \lambda_k, & k=1, 2, \dots, K_1 \\ \mu_l, & k=K_1+l, l=1, 2, \dots, K_2 \end{cases}$

$P(y|x) = \frac{1}{Z(x)} \exp \left\{ \sum_{k=1}^K w_k f_k(y, x) \right\}, \quad Z(x) = \sum_y \exp \left\{ \sum_{k=1}^K w_k f_k(y, x) \right\}$

$w = (w_1, w_2, \dots, w_K)^T$ 全局 $F(y, x) = (f_1(y, x), \dots, f_K(y, x))^T$

$\exp\{w \cdot F(y, x)\}$

$\frac{1}{Z(x)} \exp\{w \cdot F(y, x)\}$

w

只是模样简化了。实际计算方法与时间是与原来一致的。

条件随机场的矩阵形式

例 11.2 给定一个由图 11.6 所示的线性链条件随机场, 观测序列 x , 状态序列 $y, i=1, 2, 3, n=3$, 标记 $y_i \in \{1, 2\}$, 假设 $y_0 = \text{start} = 1, y_4 = \text{stop} = 1$, 各个位置

$1 \times 2 \times 2 \times 2 \times 1 = 8$

224 $y_0=1$ $y_4=1$ 第 11 章 条件随机场

的随机矩阵 $M_1(x), M_2(x), M_3(x), M_4(x)$ 分别是

$M_1(x) = \frac{1}{2} \begin{bmatrix} a_{01} & a_{02} \\ 0 & 0 \end{bmatrix}, \quad M_2(x) = \frac{1}{2} \begin{bmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{bmatrix}$

$M_3(x) = \frac{1}{2} \begin{bmatrix} c_{11} & c_{12} \\ c_{21} & c_{22} \end{bmatrix}, \quad M_4(x) = \frac{1}{2} \begin{bmatrix} 1 & 0 \\ 1 & 0 \end{bmatrix}$

试求状态序列 y 以 start 为起点 stop 为终点所有路径的非规范化概率及规范化因子。

$a_{01} b_{11} c_{11}$ $a_{02} b_{21} c_{11}$
 $a_{01} b_{12} c_{21}$ $a_{02} b_{22} c_{12}$
 $a_{01} b_{11} c_{12}$ $a_{02} b_{21} c_{22}$
 $a_{01} b_{12} c_{22}$ $a_{02} b_{22} c_{22}$

$M_i(x)$ 对应的行和列都是 y 的特征数量，即矩阵大小为 $M \times M$ 。
最后计算方式也不是矩阵的乘法，而是根据矩阵来做转移而已。

概率计算问题

前向向量

前向向量: $i=0, 1, \dots, n+1$ y_i 状态有 m 个 m 维

$\alpha_i(y_i | x) = \begin{cases} 1 & y_i = \text{start} \\ 0 & \text{否则} \end{cases}$ 例: $S = \{1, 2\}$

$\alpha_0(y_0 | x) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

递推公式: $\alpha_i^T(y_i | x) = \alpha_{i-1}^T(y_{i-1} | x) M_i(y_{i-1}, y_i | x)$

即 $\alpha_i^T(x) = \alpha_{i-1}^T(x) M_i(x), i=1, \dots, n+1$

第 i 个位置处于 y_i 状态 从 1 到 i 的 ... 非规范化概率

例: $\alpha_1^T(y_1 | x) = \alpha_0^T(y_0 | x) M_1(x)$ $\alpha_1(y_1)$

$= (0, 1) \begin{bmatrix} 0 & 0 \\ 0.5 & 0.5 \end{bmatrix} = (0.5, 0.5)$

后向向量

$\alpha_2^T(y_2 | x) = (0.5, 0.5) \begin{bmatrix} 0.3 & 0.7 \\ 0.7 & 0.3 \end{bmatrix} = (0.5, 0.5)$ $\alpha_2(y_2 | x) = \begin{pmatrix} 0.5 \\ 0.5 \end{pmatrix}$

$\alpha_3^T(y_3 | x) = (0.5, 0.5) \begin{bmatrix} 0.5 & 0.5 \\ 0.6 & 0.4 \end{bmatrix} = (0.55, 0.45)$ $\alpha_3(y_3 | x) = \begin{pmatrix} 0.55 \\ 0.45 \end{pmatrix}$

$\alpha_4^T(y_4 | x) = (0.55, 0.45) \begin{bmatrix} 0 & 1 \\ 0 & 1 \end{bmatrix} = (0, 1)$ $\alpha_4(y_4 | x) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

后向向量: $\beta_{n+1}(y_{n+1} | x) = \begin{cases} 1 & y_{n+1} = \text{stop} \\ 0 & \text{否则} \end{cases}$

例: $\beta_4(y_4 | x) = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

递推公式 $\beta_i(x) = M_{i+1}(x) \beta_{i+1}(x)$

(上面的是前向向量的计算步骤，下面的是后向向量)

计算结果

经过上面的计算，我们可以得到：

概率计算 Janneil博士 Bilibili

$$P(Y_i = y_i | x) = \frac{\alpha_i^T(y_i | x) \beta_i(y_i | x)}{Z(x)} \quad \leftarrow \cdot \overrightarrow{y_i}$$

例： $Z(x) = 1$

$$P(Y_1 = y_1 | x) = \alpha_1^T(y_1 | x) \beta_1(y_1 | x)$$
$$= (0.5, 0.5) \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad \leftarrow \begin{matrix} y_{i-1} \\ \vdots \\ y_i \end{matrix} \quad \begin{matrix} y_i \\ \vdots \\ y_i \end{matrix} \rightarrow$$
$$= 1$$
$$P(Y_{i-1} = y_{i-1}, Y_i = y_i | x) = \frac{\alpha_{i-1}^T(y_{i-1} | x) M_i(y_{i-1}, y_i | x) \beta_i(y_i | x)}{Z(x)}$$

针对于概率计算，利用前向和后向向量相乘可以直接得到某一点的概率。如果想要得到某一组点的概率需要 $\times$ 对应的 M_i 矩阵。

针对于 $Z(x)$ 的计算，也有多种方法：

注： $Z(x) = [M_1, M_2, M_3, \dots, M_{n+1}]_{start, stop}$

$$Z(x) = \alpha_{n+1}^T(x) \mathbf{1} = \mathbf{1}^T \beta_0(x)$$

例： $(0, 1) \begin{pmatrix} 1 \\ 1 \end{pmatrix} = 1 \quad (1, 1) \begin{pmatrix} 0 \\ 1 \end{pmatrix} = 1$

条件随机场的学习算法

总览

我们的目标是优化模型参数 w_k 。

条件随机场的学习算法

- ① 运用数据：时序
- ② 模型结构：对数线性模型
- ③ 学习方法：估计模型参数
 - MLE
 - 正则MLE

目标函数 w_k 求解？
- ④ 优化算法：
 - 梯度下降法
 - 拟牛顿法
 - LLS

$P(y|x) = \frac{\exp(\sum_{k=1}^K w_k f_k(y, x))}{Z(x)}$

其中 $Z(x) = \sum_y \exp(\sum_{k=1}^K w_k f_k(y, x))$

w_k 模型参数 未知

f_k 特征 已知

w_k ?

最大似然函数

最终化简得到的最大似然函数为：

$$L(w) = \sum_{x,y} \hat{P}(x,y) \left[\sum_{k=1}^K w_k f_k(y,x) \right] - \sum_x \hat{P}(x) \log Z_w(x)$$

优化算法

最速梯度下降法

前景提要

关于最速梯度下降法，方法核心就是“走一步看一步”。目标函数，

$$Q(w) = \sum_x \bar{P}(x) \log \sum_y \underbrace{\exp\left(\sum_{k=1}^K w_k f_k(y,x)\right)}_{Z_w(x)} - \sum_{x,y} \bar{P}(x,y) \sum_{k=1}^K w_k f_k(y,x)$$

求解条件随机场模型的问题转为最小化问题，

$$w^* = \arg \min_w Q(w)$$

梯度为：

$$g(w) = \nabla Q(w) = \left(\frac{\partial Q(w)}{\partial w_1}, \frac{\partial Q(w)}{\partial w_2}, \dots, \frac{\partial Q(w)}{\partial w_K} \right)^T$$

这里需要借助求导的链式法则依次求出每一个偏导数，梯度向量中的第 i 个元素为

$$\frac{\partial Q(w)}{\partial w_k} = \sum_x \bar{P}(x) \frac{\sum_y \underbrace{\exp(\sum_{k=1}^K w_k f_k(y,x)) \cdot f_k(y,x)}_{\sum_y \exp(\sum_{k=1}^K w_k f_k(y,x))}}{\sum_y \exp(\sum_{k=1}^K w_k f_k(y,x))} - \sum_{x,y} \bar{P}(x,y) f_k(y,x) \tag{1}$$

利用条件概率公式和概率期望的定义，式 (1) 可以简化表示为式 (2)：

$$\frac{\partial Q(w)}{\partial w_k} = \sum_x \bar{P}(x) P_{w'}(y|x) f_k(y,x) - E_P(f_k), \quad k = 1, 2, \dots, K \tag{2}$$

具体算法

输入：特征函数 $f_1, f_2, \dots, f_K$ ；经验分布 $\tilde{P}(x)$ 和 $\tilde{P}(x, y)$ ，目标函数 $f(\omega)$ ，梯度 $g(\omega)$ ，计算精度 ϵ ；
输出： $f(\omega)$ 的最优参数值 $\hat{\omega}$ ；最优模型 $P_{\hat{\omega}}(y|x)$ 。

(1) 选取初始值 $\omega^{(0)} \in R^K$ ，置 $j = 0$ ；

(2) 计算 $f(\omega^{(j)})$ 和梯度 $g(\omega^{(j)})$ ；

(3) 计算最优步长

$$\eta^{(j)} = \arg \min_{\eta} f(\omega^{(j)}) - \eta g(\omega^{(j)})$$

(4) 利用迭代公式 $\omega^{(j+1)} = \omega^{(j)} - \eta^{(j)} g(\omega^{(j)})$ 进行参数更新；

(5) 如果 $|f(\omega^{(j+1)}) - f(\omega^{(j)})| < \epsilon$ ，停止迭代，令 $\hat{\omega} = \omega^{(j+1)}$ ，输出结果。否则，令 $j = j + 1$ ，转 (2) 继续迭代，更新参数，直到满足终止条件；

(6) 将所得 $\hat{\omega}$ 代入 $P_{\omega}(y|x)$ 中，即得最优条件随机场模型

$$P_{\hat{\omega}}(y|x) = \frac{\exp\left(\sum_{k=1}^K \hat{\omega}_k f_k(y, x)\right)}{\sum_y \exp\left(\sum_{k=1}^K \hat{\omega}_k f_k(y, x)\right)}$$

改进的迭代尺度法

算法 11.1（条件随机场模型学习的改进的迭代尺度法）

输入：特征函数 $t_1, t_2, \dots, t_{K_1}$ ， $s_1, s_2, \dots, s_{K_2}$ ；经验分布 $\tilde{P}(x, y)$ ；

输出：参数估计值 $\hat{w}$ ；模型 $P_{\hat{w}}$ 。

(1) 对所有 $k \in \{1, 2, \dots, K\}$ ，取初值 $w_k = 0$ ；

(2) 对每一 $k \in \{1, 2, \dots, K\}$ ：

(a) 当 $k = 1, 2, \dots, K_1$ 时，令 δ_k 是方程

$$\sum_{x, y} \tilde{P}(x) P(y|x) \sum_{i=1}^{n+1} t_k(y_{i-1}, y_i, x, i) \exp(\delta_k T(x, y)) = E_{\tilde{P}}[t_k]$$

的解；

当 $k = K_1 + l$ ， $l = 1, 2, \dots, K_2$ 时，令 δ_{K_1+l} 是方程

$$\sum_{x, y} \tilde{P}(x) P(y|x) \sum_{i=1}^n s_l(y_i, x, i) \exp(\delta_{K_1+l} T(x, y)) = E_{\tilde{P}}[s_l]$$

的解，式中 $T(x, y)$ 由式 (11.38) 给出。

(b) 更新 w_k 值： $w_k \leftarrow w_k + \delta_k$

(3) 如果不是所有 w_k 都收敛，重复步骤 (2)。

条件随机场预测

维特比算法

基础的推理条件

已知: $P(Y|X)$. 输入/观测 x

未知: y 输出序列

$$\begin{aligned} y^* &= \arg \max_y P_w(y|x) && \text{最优路径} \\ &= \arg \max_y \frac{\exp(w \cdot F(y, x))}{Z_w(x)} && \text{朴素贝叶斯} \\ &= \arg \max_y \exp(w \cdot F(y, x)) \\ &= \arg \max_y (w \cdot F(y, x)) \end{aligned}$$

具体的算法:

算法 11.3 (条件随机场预测的维特比算法)

输入: 模型特征向量 $F(y, x)$ 和权值向量 w , 观测序列 $x = (x_1, x_2, \dots, x_n)$:

输出: 最优路径 $y^* = (y_1^*, y_2^*, \dots, y_n^*)$.

(1) 初始化

$$\delta_1(j) = w \cdot F_1(y_0 = \text{start}, y_1 = j, x), \quad j = 1, 2, \dots, m$$

(2) 递推. 对 $i = 2, 3, \dots, n$

$$\delta_i(l) = \max_{1 \leq j \leq m} \{\delta_{i-1}(j) + w \cdot F_i(y_{i-1} = j, y_i = l, x)\}, \quad l = 1, 2, \dots, m$$

$$\psi_i(l) = \arg \max_{1 \leq j \leq m} \{\delta_{i-1}(j) + w \cdot F_i(y_{i-1} = j, y_i = l, x)\}, \quad l = 1, 2, \dots, m$$

(3) 终止

$$\max_y (w \cdot F(y, x)) = \max_{1 \leq j \leq m} \delta_n(j)$$

$$y_n^* = \arg \max_{1 \leq j \leq m} \delta_n(j)$$

(4) 返回路径

$$y_i^* = \psi_{i+1}(y_{i+1}^*), \quad i = n-1, n-2, \dots, 1$$

求得最优路径 $y^* = (y_1^*, y_2^*, \dots, y_n^*)$.

w 是权值, $F()$ 是特征函数值, 具体可以参考这个例子。

例 11.3 设有一标注问题，输入观测序列为 $X = (X_1, X_2, X_3)$ ，输出标注序列为 $Y = (Y_1, Y_2, Y_3)$ ， Y_1, Y_2, Y_3 取值于 $\mathcal{Y} = \{1, 2\}$ 。

假设特征 t_i, s_i, μ_i 和对应的权值 λ_i, μ_i 如下：

$$t_i = t_i(y_{i-1} = 1, y_i = 2, x, i), \quad i = 2, 3, \quad \lambda_i = 1$$

这里只注明特征取值为 1 的条件，取值为 0 的条件省略，即

$$t_i(y_{i-1}, y_i, x, i) = \begin{cases} 1, & y_{i-1} = 1, y_i = 2, x, i = (2, 3) \\ 0, & \text{其他} \end{cases}$$

下同。

$$t_2 = t_2(y_1 = 1, y_2 = 1, x, 2), \quad \lambda_2 = 0.6$$

$$t_3 = t_3(y_2 = 2, y_3 = 1, x, 3), \quad \lambda_3 = 1$$

$$t_4 = t_4(y_1 = 2, y_2 = 1, x, 2), \quad \lambda_4 = 1$$

$$t_5 = t_5(y_1 = 2, y_2 = 2, x, 3), \quad \lambda_5 = 0.2$$

$$s_1 = s_1(y_1 = 1, x, 1), \quad \mu_1 = 1$$

$$s_2 = s_2(y_1 = 2, x, i), i = 1, 2, \quad \mu_2 = 0.5$$

$$s_3 = s_3(y_1 = 1, x, i), i = 2, 3, \quad \mu_3 = 0.8$$

$$s_4 = s_4(y_2 = 2, x, 3), \quad \mu_4 = 0.5$$

对给定的观测序列 x ，求标注序列 y ，使得 $\sum_{i=1}^3 \lambda_i t_i(y_{i-1}, y_i, x, i) + \sum_{i=1}^3 \mu_i s_i(y_i, x, i)$ 最大。

Janneil博士 Bilibili

初始状态 权值 特征函数 权值

状态	权值	特征函数	权值
$S_1 = 1$	$\mu_1 = 1$	$t_2 = 1$	$\lambda_2 = 0.6$
$S_2 = 1$	$\mu_2 = 0.5$	$t_3 = 1$	$\lambda_3 = 1$
$S_3 = 1$	$\mu_3 = 0.8$	$t_4 = 1$	$\lambda_4 = 1$
$S_4 = 1$	$\mu_4 = 0.5$	$t_5 = 0.2$	$\lambda_5 = 0.2$
$S_5 = 1$	$\mu_5 = 0.5$	$t_6 = 1$	$\lambda_6 = 1$
$S_6 = 1$	$\mu_6 = 0.5$	$t_7 = 1$	$\lambda_7 = 1$
$S_7 = 1$	$\mu_7 = 0.5$	$t_8 = 1$	$\lambda_8 = 1$
$S_8 = 1$	$\mu_8 = 0.5$	$t_9 = 1$	$\lambda_9 = 1$
$S_9 = 1$	$\mu_9 = 0.5$	$t_{10} = 1$	$\lambda_{10} = 1$
$S_{10} = 1$	$\mu_{10} = 0.5$	$t_{11} = 1$	$\lambda_{11} = 1$
$S_{11} = 1$	$\mu_{11} = 0.5$	$t_{12} = 1$	$\lambda_{12} = 1$
$S_{12} = 1$	$\mu_{12} = 0.5$	$t_{13} = 1$	$\lambda_{13} = 1$
$S_{13} = 1$	$\mu_{13} = 0.5$	$t_{14} = 1$	$\lambda_{14} = 1$
$S_{14} = 1$	$\mu_{14} = 0.5$	$t_{15} = 1$	$\lambda_{15} = 1$
$S_{15} = 1$	$\mu_{15} = 0.5$	$t_{16} = 1$	$\lambda_{16} = 1$
$S_{16} = 1$	$\mu_{16} = 0.5$	$t_{17} = 1$	$\lambda_{17} = 1$
$S_{17} = 1$	$\mu_{17} = 0.5$	$t_{18} = 1$	$\lambda_{18} = 1$
$S_{18} = 1$	$\mu_{18} = 0.5$	$t_{19} = 1$	$\lambda_{19} = 1$
$S_{19} = 1$	$\mu_{19} = 0.5$	$t_{20} = 1$	$\lambda_{20} = 1$
$S_{20} = 1$	$\mu_{20} = 0.5$	$t_{21} = 1$	$\lambda_{21} = 1$
$S_{21} = 1$	$\mu_{21} = 0.5$	$t_{22} = 1$	$\lambda_{22} = 1$
$S_{22} = 1$	$\mu_{22} = 0.5$	$t_{23} = 1$	$\lambda_{23} = 1$
$S_{23} = 1$	$\mu_{23} = 0.5$	$t_{24} = 1$	$\lambda_{24} = 1$
$S_{24} = 1$	$\mu_{24} = 0.5$	$t_{25} = 1$	$\lambda_{25} = 1$
$S_{25} = 1$	$\mu_{25} = 0.5$	$t_{26} = 1$	$\lambda_{26} = 1$
$S_{26} = 1$	$\mu_{26} = 0.5$	$t_{27} = 1$	$\lambda_{27} = 1$
$S_{27} = 1$	$\mu_{27} = 0.5$	$t_{28} = 1$	$\lambda_{28} = 1$
$S_{28} = 1$	$\mu_{28} = 0.5$	$t_{29} = 1$	$\lambda_{29} = 1$
$S_{29} = 1$	$\mu_{29} = 0.5$	$t_{30} = 1$	$\lambda_{30} = 1$
$S_{30} = 1$	$\mu_{30} = 0.5$	$t_{31} = 1$	$\lambda_{31} = 1$
$S_{31} = 1$	$\mu_{31} = 0.5$	$t_{32} = 1$	$\lambda_{32} = 1$
$S_{32} = 1$	$\mu_{32} = 0.5$	$t_{33} = 1$	$\lambda_{33} = 1$
$S_{33} = 1$	$\mu_{33} = 0.5$	$t_{34} = 1$	$\lambda_{34} = 1$
$S_{34} = 1$	$\mu_{34} = 0.5$	$t_{35} = 1$	$\lambda_{35} = 1$
$S_{35} = 1$	$\mu_{35} = 0.5$	$t_{36} = 1$	$\lambda_{36} = 1$
$S_{36} = 1$	$\mu_{36} = 0.5$	$t_{37} = 1$	$\lambda_{37} = 1$
$S_{37} = 1$	$\mu_{37} = 0.5$	$t_{38} = 1$	$\lambda_{38} = 1$
$S_{38} = 1$	$\mu_{38} = 0.5$	$t_{39} = 1$	$\lambda_{39} = 1$
$S_{39} = 1$	$\mu_{39} = 0.5$	$t_{40} = 1$	$\lambda_{40} = 1$
$S_{40} = 1$	$\mu_{40} = 0.5$	$t_{41} = 1$	$\lambda_{41} = 1$
$S_{41} = 1$	$\mu_{41} = 0.5$	$t_{42} = 1$	$\lambda_{42} = 1$
$S_{42} = 1$	$\mu_{42} = 0.5$	$t_{43} = 1$	$\lambda_{43} = 1$
$S_{43} = 1$	$\mu_{43} = 0.5$	$t_{44} = 1$	$\lambda_{44} = 1$
$S_{44} = 1$	$\mu_{44} = 0.5$	$t_{45} = 1$	$\lambda_{45} = 1$
$S_{45} = 1$	$\mu_{45} = 0.5$	$t_{46} = 1$	$\lambda_{46} = 1$
$S_{46} = 1$	$\mu_{46} = 0.5$	$t_{47} = 1$	$\lambda_{47} = 1$
$S_{47} = 1$	$\mu_{47} = 0.5$	$t_{48} = 1$	$\lambda_{48} = 1$
$S_{48} = 1$	$\mu_{48} = 0.5$	$t_{49} = 1$	$\lambda_{49} = 1$
$S_{49} = 1$	$\mu_{49} = 0.5$	$t_{50} = 1$	$\lambda_{50} = 1$
$S_{50} = 1$	$\mu_{50} = 0.5$	$t_{51} = 1$	$\lambda_{51} = 1$
$S_{51} = 1$	$\mu_{51} = 0.5$	$t_{52} = 1$	$\lambda_{52} = 1$
$S_{52} = 1$	$\mu_{52} = 0.5$	$t_{53} = 1$	$\lambda_{53} = 1$
$S_{53} = 1$	$\mu_{53} = 0.5$	$t_{54} = 1$	$\lambda_{54} = 1$
$S_{54} = 1$	$\mu_{54} = 0.5$	$t_{55} = 1$	$\lambda_{55} = 1$
$S_{55} = 1$	$\mu_{55} = 0.5$	$t_{56} = 1$	$\lambda_{56} = 1$
$S_{56} = 1$	$\mu_{56} = 0.5$	$t_{57} = 1$	$\lambda_{57} = 1$
$S_{57} = 1$	$\mu_{57} = 0.5$	$t_{58} = 1$	$\lambda_{58} = 1$
$S_{58} = 1$	$\mu_{58} = 0.5$	$t_{59} = 1$	$\lambda_{59} = 1$
$S_{59} = 1$	$\mu_{59} = 0.5$	$t_{60} = 1$	$\lambda_{60} = 1$
$S_{60} = 1$	$\mu_{60} = 0.5$	$t_{61} = 1$	$\lambda_{61} = 1$
$S_{61} = 1$	$\mu_{61} = 0.5$	$t_{62} = 1$	$\lambda_{62} = 1$
$S_{62} = 1$	$\mu_{62} = 0.5$	$t_{63} = 1$	$\lambda_{63} = 1$
$S_{63} = 1$	$\mu_{63} = 0.5$	$t_{64} = 1$	$\lambda_{64} = 1$
$S_{64} = 1$	$\mu_{64} = 0.5$	$t_{65} = 1$	$\lambda_{65} = 1$
$S_{65} = 1$	$\mu_{65} = 0.5$	$t_{66} = 1$	$\lambda_{66} = 1$
$S_{66} = 1$	$\mu_{66} = 0.5$	$t_{67} = 1$	$\lambda_{67} = 1$
$S_{67} = 1$	$\mu_{67} = 0.5$	$t_{68} = 1$	$\lambda_{68} = 1$
$S_{68} = 1$	$\mu_{68} = 0.5$	$t_{69} = 1$	$\lambda_{69} = 1$
$S_{69} = 1$	$\mu_{69} = 0.5$	$t_{70} = 1$	$\lambda_{70} = 1$
$S_{70} = 1$	$\mu_{70} = 0.5$	$t_{71} = 1$	$\lambda_{71} = 1$
$S_{71} = 1$	$\mu_{71} = 0.5$	$t_{72} = 1$	$\lambda_{72} = 1$
$S_{72} = 1$	$\mu_{72} = 0.5$	$t_{73} = 1$	$\lambda_{73} = 1$
$S_{73} = 1$	$\mu_{73} = 0.5$	$t_{74} = 1$	$\lambda_{74} = 1$
$S_{74} = 1$	$\mu_{74} = 0.5$	$t_{75} = 1$	$\lambda_{75} = 1$
$S_{75} = 1$	$\mu_{75} = 0.5$	$t_{76} = 1$	$\lambda_{76} = 1$
$S_{76} = 1$	$\mu_{76} = 0.5$	$t_{77} = 1$	$\lambda_{77} = 1$
$S_{77} = 1$	$\mu_{77} = 0.5$	$t_{78} = 1$	$\lambda_{78} = 1$
$S_{78} = 1$	$\mu_{78} = 0.5$	$t_{79} = 1$	$\lambda_{79} = 1$
$S_{79} = 1$	$\mu_{79} = 0.5$	$t_{80} = 1$	$\lambda_{80} = 1$
$S_{80} = 1$	$\mu_{80} = 0.5$	$t_{81} = 1$	$\lambda_{81} = 1$
$S_{81} = 1$	$\mu_{81} = 0.5$	$t_{82} = 1$	$\lambda_{82} = 1$
$S_{82} = 1$	$\mu_{82} = 0.5$	$t_{83} = 1$	$\lambda_{83} = 1$
$S_{83} = 1$	$\mu_{83} = 0.5$	$t_{84} = 1$	$\lambda_{84} = 1$
$S_{84} = 1$	$\mu_{84} = 0.5$	$t_{85} = 1$	$\lambda_{85} = 1$
$S_{85} = 1$	$\mu_{85} = 0.5$	$t_{86} = 1$	$\lambda_{86} = 1$
$S_{86} = 1$	$\mu_{86} = 0.5$	$t_{87} = 1$	$\lambda_{87} = 1$
$S_{87} = 1$	$\mu_{87} = 0.5$	$t_{88} = 1$	$\lambda_{88} = 1$
$S_{88} = 1$	$\mu_{88} = 0.5$	$t_{89} = 1$	$\lambda_{89} = 1$
$S_{89} = 1$	$\mu_{89} = 0.5$	$t_{90} = 1$	$\lambda_{90} = 1$
$S_{90} = 1$	$\mu_{90} = 0.5$	$t_{91} = 1$	$\lambda_{91} = 1$
$S_{91} = 1$	$\mu_{91} = 0.5$	$t_{92} = 1$	$\lambda_{92} = 1$
$S_{92} = 1$	$\mu_{92} = 0.5$	$t_{93} = 1$	$\lambda_{93} = 1$
$S_{93} = 1$	$\mu_{93} = 0.5$	$t_{94} = 1$	$\lambda_{94} = 1$
$S_{94} = 1$	$\mu_{94} = 0.5$	$t_{95} = 1$	$\lambda_{95} = 1$
$S_{95} = 1$	$\mu_{95} = 0.5$	$t_{96} = 1$	$\lambda_{96} = 1$
$S_{96} = 1$	$\mu_{96} = 0.5$	$t_{97} = 1$	$\lambda_{97} = 1$
$S_{97} = 1$	$\mu_{97} = 0.5$	$t_{98} = 1$	$\lambda_{98} = 1$
$S_{98} = 1$	$\mu_{98} = 0.5$	$t_{99} = 1$	$\lambda_{99} = 1$
$S_{99} = 1$	$\mu_{99} = 0.5$	$t_{100} = 1$	$\lambda_{100} = 1$

对于给定的 x ，最优路径 y^*

$$\delta_2(2) = \max \left\{ \begin{aligned} &\delta_1(1) + w \cdot F_2(1, 2, x) \\ &\delta_1(2) + w \cdot F_2(2, 2, x) \end{aligned} \right\} = \max \left\{ \begin{aligned} &1 + t_1 \lambda_1 + s_1 \mu_1 \\ &0.5 + 0 + s_2 \mu_2 \end{aligned} \right\}$$

$$= \max \left\{ \begin{aligned} &1 + 1 + 0.5 \\ &0.5 + 0 + 0.5 \end{aligned} \right\} = \max \left\{ \begin{aligned} &2.5 \\ &1 \end{aligned} \right\} = 2.5$$

$\Psi_2(2) = 1$